Julian David Rangel - 89721

Laboratorio comprensión de los datos

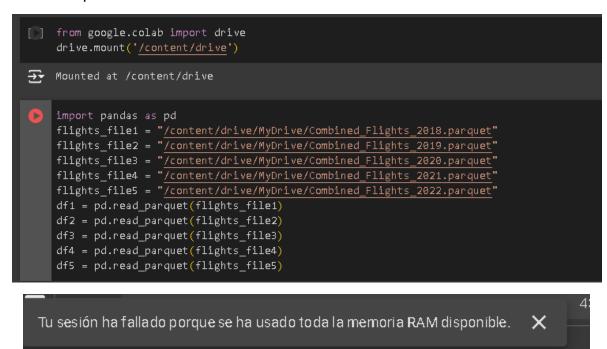
Objetivo Laboratorio

Comparar el desempeño de librerías de Python para carga y manipulación de datos tabulares.

Desarrollo Laboratorio

Librería Pandas

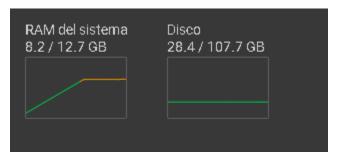
Primero comenzamos ejecutando la librería pandas con todos los paquetes y notamos que ocurre una saturación en la RAM al rededor del minuto 1:30.



Realizando pruebas nos damos cuenta que la mejor manera de ejecutar los paquetes es con los 3 más ligeros y luego los dos más pesados.

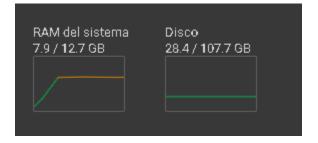
 Primero con los 3 más ligeros notamos un máximo de 8.2 GB de RAM en 24 segundos.

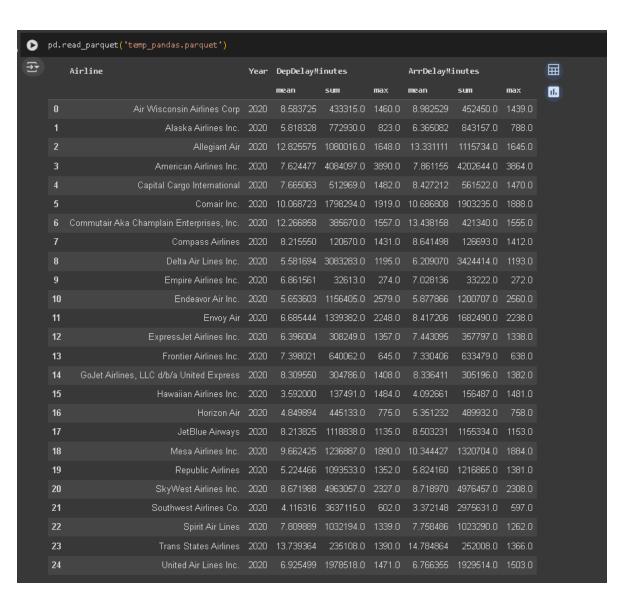
```
import pandas as pd
flights_file1 = "/content/drive/MyDrive/Combined_Flights_2018.parquet"
#flights_file2 = "/content/drive/MyDrive/Combined_Flights_2019.parquet"
flights_file3 = "/content/drive/MyDrive/Combined_Flights_2020.parquet"
#flights_file4 = "/content/drive/MyDrive/Combined_Flights_2021.parquet"
flights_file5 = "/content/drive/MyDrive/Combined_Flights_2022.parquet"
df1 = pd.read_parquet(flights_file1)
#df2 = pd.read_parquet(flights_file2)
df3 = pd.read_parquet(flights_file3)
#df4 = pd.read_parquet(flights_file4)
df5 = pd.read_parquet(flights_file5)
```

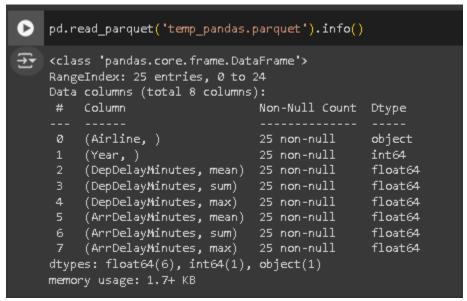


 Segundo con los 2 paquetes más pesados notamos un máximo de 7.9 GB de RAM en 32 segundos, tomando mas tiempo incluso que con los 3 paquetes.

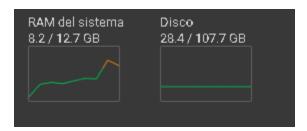
```
import pandas as pd
#flights_file1 = "/content/drive/MyDrive/Combined_Flights_2018.parquet"
flights_file2 = "/content/drive/MyDrive/Combined_Flights_2019.parquet"
#flights_file3 = "/content/drive/MyDrive/Combined_Flights_2020.parquet"
flights_file4 = "/content/drive/MyDrive/Combined_Flights_2021.parquet"
#flights_file5 = "/content/drive/MyDrive/Combined_Flights_2022.parquet"
#df1 = pd.read_parquet(flights_file1)
df2 = pd.read_parquet(flights_file2)
#df3 = pd.read_parquet(flights_file3)
df4 = pd.read_parquet(flights_file4)
#df5 = pd.read_parquet(flights_file5)
```







Y finalmente aumentando alrededor de 0.3 en Ram con el resto del código.



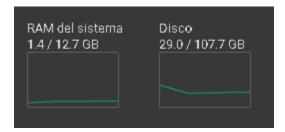
Librería Polars

Primero comenzamos ejecutando la librería polars con todos los paquetes y notamos que ejecuta todos los paquetes en 2 segundos con un uso de ram de 1.3 GB.

```
flights_file1 = "/content/drive/MyDrive/Combined_Flights_2018.parquet"
flights_file2 = "/content/drive/MyDrive/Combined_Flights_2019.parquet"
flights_file3 = "/content/drive/MyDrive/Combined_Flights_2020.parquet"
flights_file4 = "/content/drive/MyDrive/Combined_Flights_2021.parquet"
flights_file5 = "/content/drive/MyDrive/Combined_Flights_2021.parquet"
flights_file5 = "/content/drive/MyDrive/Combined_Flights_2022.parquet"
df1 = pl.scan_parquet(flights_file1)
df2 = pl.scan_parquet(flights_file2)
df3 = pl.scan_parquet(flights_file3)
df4 = pl.scan_parquet(flights_file4)
df5 = pl.scan_parquet(flights_file5)
```



Aunque notamos bastante tiempo en el resto del código con la librería de 1.32 segundos y un aumento de 0.1 GB de RAM.



Librería Spark

Primero comenzamos ejecutando la librería polars con todos los paquetes y notamos que ejecuta todos los paquetes en menos de 1 segundo con un uso de ram de 1.3 GB.

```
flights_file1 = "/content/drive/MyDrive/Combined_Flights_2018.parquet"
flights_file2 = "/content/drive/MyDrive/Combined_Flights_2019.parquet"
flights_file3 = "/content/drive/MyDrive/Combined_Flights_2020.parquet"
flights_file4 = "/content/drive/MyDrive/Combined_Flights_2021.parquet"
flights_file5 = "/content/drive/MyDrive/Combined_Flights_2022.parquet"
```



Y con el resto del código ejecutando alrededor de 10 segundos con un aumento de 0.6 GB de RAM.

```
[11] df spark1 = spark.read.parquet(flights file1)
    df spark2 = spark.read.parquet(flights file2)
    df spark3 = spark.read.parquet(flights file3)
    df spark4 = spark.read.parquet(flights file4)
    df_spark5 = spark.read.parquet(flights_file5)
[12] df_spark = df_spark1.union(df_spark2)
     df_spark = df_spark.union(df_spark3)
     df_spark = df_spark.union(df_spark4)
     df_spark = df_spark.union(df_spark5)
df spark agg = df spark.groupby("Airline", "Year").agg(
        avg("ArrDelayMinutes").alias('avg_arr_delay'),
        sum("ArrDelayMinutes").alias('sum_arr_delay'),
        max("ArrDelayMinutes").alias('max_arr_delay'),
        avg("DepDelayMinutes").alias('avg_dep_delay'),
        sum("DepDelayMinutes").alias('sum_dep_delay'),
        max("DepDelayMinutes").alias('max_dep_delay'),
    df_spark_agg.write.mode('overwrite').parquet('temp_spark.parquet')
```

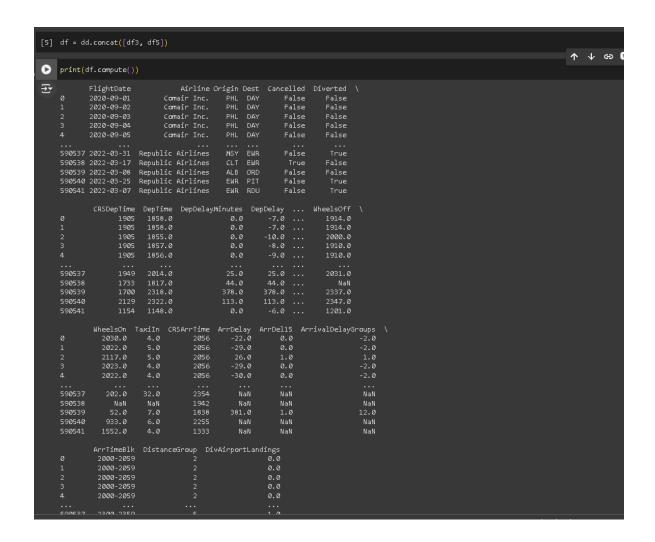
Librería Dask

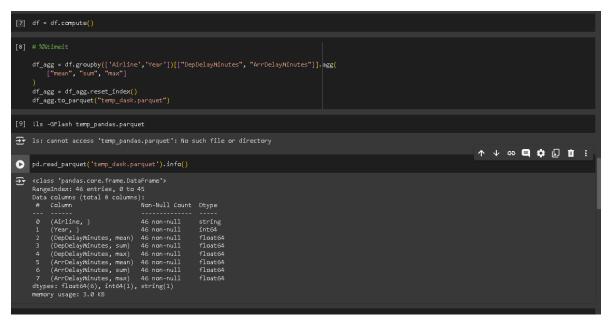
Primero comenzamos ejecutando la librería polars con todos los paquetes y notamos que ejecuta todos los paquetes en 1 segundo con un uso de ram de 1.3 GB.

```
import pandas as pd
import dask.dataframe as dd
flights_file1 = "/content/drive/MyDrive/Combined_Flights_2018.parquet"
flights_file2 = "/content/drive/MyDrive/Combined_Flights_2019.parquet"
flights_file3 = "/content/drive/MyDrive/Combined_Flights_2020.parquet"
flights_file4 = "/content/drive/MyDrive/Combined_Flights_2021.parquet"
flights_file5 = "/content/drive/MyDrive/Combined_Flights_2022.parquet"
df1 = dd.read_parquet(flights_file1)
df2 = dd.read_parquet(flights_file2)
df3 = dd.read_parquet(flights_file3)
df4 = dd.read_parquet(flights_file4)
df5 = dd.read_parquet(flights_file5)
```



Y con el resto del código ejecutando alrededor de 30 segundos con un aumento de 5.0 GB de RAM.

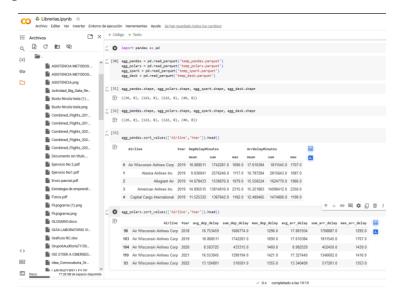




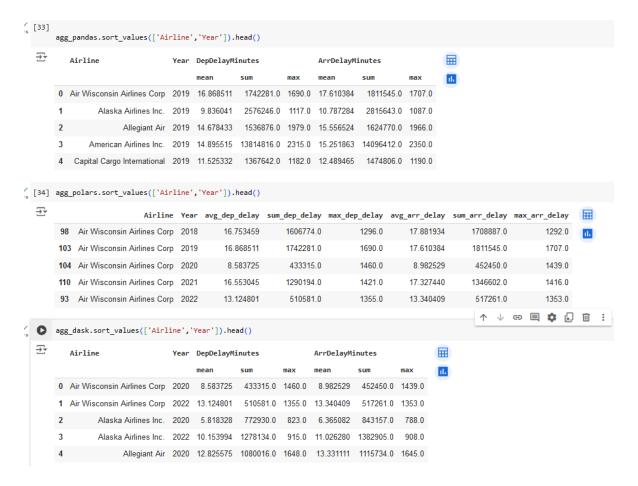


0	nd n	read parquet('temp dask.parquet')								↑ •	6
	4	Air Wisconsin Airlines Corp	ากาา	10 104001	510581.0	1355.0	13.340409	517261.0	1353.0		
∑											
	2	Alaska Airlines Inc.	2020	5.818328	772930.0	823.0	6.365082	843157.0	788.0		
	3	Alaska Airlines Inc.	2022	10.153994	1278134.0	915.0	11.026280	1382905.0	908.0		
	4	Allegiant Air	2020	12.825575	1080016.0	1648.0	13.331111	1115734.0	1645.0		
	5	Allegiant Air	2022	22.688601	1602632.0	1917.0	25.350068	1785963.0	1919.0		
	6	American Airlines Inc.	2020	7.624477	4084097.0	3890.0	7.861155	4202644.0	3864.0		
	7	American Airlines Inc.	2022	17.718716	8464195.0	2994.0	17.860139	8499122.0	2977.0		
	8	Capital Cargo International	2020	7.665063	512969.0	1482.0	8.427212	561522.0	1470.0		
	9	Capital Cargo International	2022	12.052814	619599.0	1512.0	13.050802	667418.0	1490.0		
	10	Comair Inc.	2020	10.068723	1798294.0	1919.0	10.686808	1903235.0	1888.0		
	11	Comair Inc.	2022	16.925615	2212601.0	1607.0	17.623038	2293374.0	1612.0		
	12	Commutair Aka Champlain Enterprises, Inc.	2020	12.266858	385670.0	1557.0	13.438158	421340.0	1555.0		
	13	Commutair Aka Champlain Enterprises, Inc.	2022	16.342795	700730.0	1464.0	17.008007	726497.0	1456.0		
	14	Compass Airlines	2020	8.215550	120670.0	1431.0	8.641498	126693.0	1412.0		
	15	Delta Air Lines Inc.	2020	5.581694	3083283.0	1195.0	6.209070	3424414.0	1193.0		
	16	Delta Air Lines Inc.	2022	13.842472	6948367.0	1287.0	13.111550	6565084.0	1285.0		
	17	Empire Airlines Inc.	2020	6.861561	32613.0	274.0	7.028136	33222.0	272.0		
	18	Endeavor Air Inc.	2020	5.653603	1156405.0	2579.0	5.877866	1200707.0	2560.0		
	19	Endeavor Air Inc.	2022	13.284602	1819220.0	1973.0	14.184149	1935952.0	1968.0		

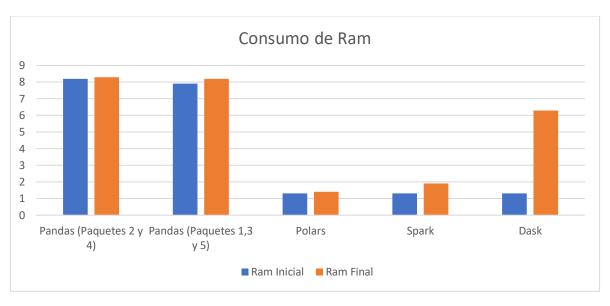
Final del código con las librerías







Resultados



Conclusión

Luego de realizar las pruebas con las librerías de Pandas, Polars, Spark y Dask, Se concluye que:

- En cuanto carga de paquetes Polars, Spark son bastantes ligeras, cargan y ejecutan el código de manera rápida y efectiva, sin generar tanta carga de RAM.
- En cuanto a la librería Dask también es bastante rápida en la carga y ejecución, pero nos consume más RAM durante el proceso.
- En cuanto a la librería Pandas en cuanto a la carga de paquetes colapsaba la RAM, se realizó por partes para no saturar la RAM que nos provee Google Colabority, pero de todas maneras tiene un consumo de RAM bastante elevado a comparación de los demás.